

Modelado de las Series Temporales

Materia: Simulación de procesos

Prof. D.Sc. BARSEKH-ONJI Aboud

Facultad de Ingeniería
Universidad Anáhuac México

28 de abril de 2026

Agenda

1. Introducción al Modelado de Series Temporales
2. Análisis de Correlación Pearson
 - 2.1 Correlación de Pearson
 - 2.2 Identificación de la Dependencia Temporal: ACF y PACF
3. Pruebas Estadísticas para la detección de estacionariedad
 - 3.1 La Prueba Q de Ljung-Box
 - 3.2 Detección de Volatilidad Condicional: Prueba de Efectos ARCH
 - 3.3 Pruebas de Raíz Unitaria
 - 3.4 Ejemplo Práctico: Detección de Estacionariedad
4. Modelos Autorregresivos Integrados de Media Móvil (ARIMA)
 - 4.1 Componentes Fundamentales: Procesos AR y MA
 - 4.2 El Modelo ARMA: Combinando Dependencia Pasada y Errores Aleatorios
 - 4.3 El Modelo ARIMA: Manejando la No Estacionariedad
 - 4.4 Extensiones del Modelo ARIMA
 - 4.5 La Metodología Box-Jenkins para el Modelado ARIMA

¿Qué es una Serie Temporal?

Definición

Una **serie temporal** es una secuencia de puntos de datos medidos en instantes sucesivos en el tiempo, espaciados uniformemente.

- **Análisis de series temporales:** Consiste en extraer estadísticas y características significativas de los datos.
- **Modelado de series temporales:** Es el proceso de construir un modelo estocástico que describa la estructura de la serie para poder realizar predicciones (*forecasting*).

Característica Clave: Dependencia Temporal

A diferencia de otros tipos de datos, los datos de series temporales tienen una estructura de dependencia temporal inherente: el valor de hoy a menudo depende del valor de ayer.

Modelos Autorregresivos (AR)

En las series temporales, los predictores más importantes suelen ser los propios valores pasados de la serie. Esto da lugar a los modelos **autorregresivos**, donde la serie se regresa sobre sus propios valores rezagados (*lags*).

Modelo AR de orden p , denotado como AR(p)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

Donde y_t se predice como una función lineal de sus p valores anteriores.

Herramientas y Objetivos del Capítulo

Econometric Modeler App de MATLAB

Utilizaremos este entorno interactivo que facilita todo el flujo de trabajo del modelado econométrico, desde la visualización hasta la estimación y validación de modelos complejos como ARIMA y GARCH.

Al finalizar, serás capaz de:

- Visualizar y transformar datos de series temporales.
- Realizar pruebas estadísticas para la identificación de modelos.
- Estimar y comparar modelos candidatos.
- Realizar diagnósticos de residuos.
- Generar automáticamente código o informes.

Agenda

1. Introducción al Modelado de Series Temporales
2. **Análisis de Correlación Pearson**
 - 2.1 Correlación de Pearson
 - 2.2 Identificación de la Dependencia Temporal: ACF y PACF
3. Pruebas Estadísticas para la detección de estacionariedad
 - 3.1 La Prueba Q de Ljung-Box
 - 3.2 Detección de Volatilidad Condicional: Prueba de Efectos ARCH
 - 3.3 Pruebas de Raíz Unitaria
 - 3.4 Ejemplo Práctico: Detección de Estacionariedad
4. Modelos Autorregresivos Integrados de Media Móvil (ARIMA)
 - 4.1 Componentes Fundamentales: Procesos AR y MA
 - 4.2 El Modelo ARMA: Combinando Dependencia Pasada y Errores Aleatorios
 - 4.3 El Modelo ARIMA: Manejando la No Estacionariedad
 - 4.4 Extensiones del Modelo ARIMA
 - 4.5 La Metodología Box-Jenkins para el Modelado ARIMA

El Primer Paso: Visualizar

El primer paso en cualquier análisis de series temporales es la visualización. Un gráfico de la serie a lo largo del tiempo puede revelar patrones importantes como tendencias, estacionalidad y cambios en la volatilidad.

Econometric Modeler App

Proporciona una interfaz gráfica para importar y visualizar series temporales sin necesidad de escribir código. Al importar datos, la aplicación genera automáticamente un gráfico interactivo.




Figura 1: Visualización de los índices NASDAQ y NYSE.

Definición

Para cuantificar la relación **lineal** entre dos series temporales, se utiliza el coeficiente de correlación de Pearson (ρ). Su valor varía entre -1 (correlación negativa perfecta) y +1 (correlación positiva perfecta). Un valor de 0 indica que no hay correlación lineal.

Fórmula Muestral

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Correlación de Pearson




Figura 2: La correlación Pearson entre variables

Dependencia Temporal: ACF y PACF

Para analizar la dependencia **dentro de una misma serie temporal**, se utilizan dos herramientas gráficas clave:

Función de Autocorrelación (ACF)

- Mide la correlación **total** (directa e indirecta) de una serie con sus propios valores pasados (rezagos).
- Responde a: ¿Cómo se relaciona y_t con y_{t-k} en general?

Función de Autocorrelación Parcial (PACF)

- Mide la correlación **directa** entre y_t y y_{t-k} , después de eliminar el efecto de los rezagos intermedios.
- Responde a: ¿Qué nueva información aporta y_{t-k} que no estuviera ya en $y_{t-1}, \dots, y_{t-k+1}$?

Ejemplo ACF y PACF: Detección de correlación serial en el PIB

PIB

Consideremos una serie temporal del Producto Interno Bruto (PIB) de EE. UU. Para identificar su estructura de dependencia, podemos visualizar su ACF y PACF en **Econometric Modeler**.

Se puede acceder a más detalles del este ejemplo a través del siguiente enlace del repositorio de Mathworks:

Examples

<https://la.mathworks.com/help/econ/detect-serial-correlation-using-econometric-modeler-app.html>

Identificación de Modelos ARMA con ACF y PACF

Reglas Clave de Identificación

La interpretación conjunta de la ACF y la PACF es la clave para la identificación de modelos ARMA:

Modelo Autorregresivo AR(p)

- La **PACF** se 'corta' (se vuelve no significativa) después del rezago p .
- La **ACF** decae exponencialmente.

Modelo de Media Móvil MA(q)

- La **ACF** se 'corta' después del rezago q .
- La **PACF** decae exponencialmente.

Ejemplo: Análisis de la Serie del PIB

Interpretación de los Correlogramas

- **ACF:** Decae muy lentamente, lo que es una señal clásica de una serie **no estacionaria** con una fuerte tendencia. Indica que se necesita diferenciar la serie.
- **PACF:** Se 'corta' abruptamente después del primer rezago, lo que sugiere que la dinámica de la serie (una vez diferenciada) podría ser descrita por un modelo **AR(1)**.




Figura 3: ACF y PACF de la serie temporal del PIB.

Agenda

1. Introducción al Modelado de Series Temporales
2. Análisis de Correlación Pearson
 - 2.1 Correlación de Pearson
 - 2.2 Identificación de la Dependencia Temporal: ACF y PACF
3. Pruebas Estadísticas para la detección de estacionariedad
 - 3.1 La Prueba Q de Ljung-Box
 - 3.2 Detección de Volatilidad Condicional: Prueba de Efectos ARCH
 - 3.3 Pruebas de Raíz Unitaria
 - 3.4 Ejemplo Práctico: Detección de Estacionariedad
4. Modelos Autorregresivos Integrados de Media Móvil (ARIMA)
 - 4.1 Componentes Fundamentales: Procesos AR y MA
 - 4.2 El Modelo ARMA: Combinando Dependencia Pasada y Errores Aleatorios
 - 4.3 El Modelo ARIMA: Manejando la No Estacionariedad
 - 4.4 Extensiones del Modelo ARIMA
 - 4.5 La Metodología Box-Jenkins para el Modelado ARIMA

Más Allá del Análisis Gráfico

Además del análisis visual con la ACF y la PACF, es fundamental utilizar pruebas estadísticas formales para evaluar las propiedades de una serie temporal. Estas pruebas proporcionan una base cuantitativa para tomar decisiones sobre la estructura del modelo.

Prueba Q de Ljung-Box: Detección de Autocorrelación

Propósito

Es una prueba de hipótesis que se utiliza para determinar si un grupo de autocorrelaciones de una serie temporal son estadísticamente diferentes de cero. Confirma formalmente la presencia de correlación serial.

Hipótesis

- H_0 (**Hipótesis Nula**): No hay correlación serial. Las autocorrelaciones hasta el rezago m son cero (la serie es ruido blanco).
- H_a (**Hipótesis Alternativa**): Hay correlación serial.

Prueba Q de Ljung-Box: Detección de Autocorrelación

Regla de Decisión

Si el **p-valor** < **0.05**, se rechaza H_0 , concluyendo que existe evidencia de correlación serial.

Ljung-Box Q-Test for Autocorrelation(OSHORT)								
Null Hypothesis: The first m autocorrelations of OSHORT are jointly 0								
Results								
	Select	Null Rejected	P-Value	Test Statistic	Critical Value	Lags	DOF	Significance Level
1	☐	true	0.0007	30.5986	21.7014	10	10	0.0167
2	☐	true	0.0016	19.3604	13.8338	5	5	0.0167
3	☐	true	9.5339e-05	15.2268	5.7276	1	1	0.0167

Figura 4: Resultados de la prueba en Econometric Modeler.

Examples

<https://la.mathworks.com/help/econ/detect-serial-correlation-using-econometric-modeler-app.html>

Discusión de los resultados

Para la serie del PIB no diferenciada, el p-valor resultante será extremadamente pequeño (cercano a cero). Esto nos lleva a rechazar la hipótesis nula de no correlación, confirmando de manera formal lo que la ACF sugería visualmente: la serie del PIB tiene una fuerte estructura de dependencia temporal y no es estacionaria. Este resultado refuerza la necesidad de transformar la serie (por ejemplo, mediante diferenciación) antes de proceder con el modelado.

Heterocedasticidad Condicional (ARCH)

Muchas series, especialmente las financieras, exhiben **agrupamiento de volatilidad** (*volatility clustering*): períodos de alta volatilidad son seguidos por períodos de alta volatilidad. Esto viola el supuesto de varianza constante.

Prueba ARCH de Engle

Detecta formalmente la presencia de efectos ARCH.

- H_0 : No existen efectos ARCH (la varianza de los errores es constante).
- H_a : Existen efectos ARCH.
- **Decisión:** Un p-valor bajo confirma la presencia de ARCH, indicando que se necesitan modelos como GARCH.

Examples

<https://la.mathworks.com/help/econ/detect-arch-effects-using-econometric-modeler.html>

Aplicación Práctica: Detección de Efectos ARCH en Rendimientos Cambiarios

Consideremos una serie de rendimientos diarios del tipo de cambio entre el Marco Alemán y la Libra Esterlina.

Prueba ARCH de Engle




Figura 5: Correlograma de los residuos al cuadrado, mostrando una clara dependencia.

¿Es la serie estacionaria?

Prueba de Dickey-Fuller Aumentada (ADF)

Prueba para detectar una **raíz unitaria** (característica de series no estacionarias).

- H_0 : La serie tiene una raíz unitaria (**NO es estacionaria**).
- H_a : La serie **es estacionaria**.
- *Un p-valor bajo indica estacionariedad.*

Prueba KPSS

Es una prueba para la estacionariedad, con las hipótesis invertidas, lo que la hace un excelente complemento.

- H_0 : La serie **es estacionaria**.
- H_a : La serie tiene una raíz unitaria (**NO es estacionaria**).
- *Un p-valor bajo indica no estacionariedad.*

Ejemplo: Flujo de Trabajo para Evaluar Estacionariedad

Examples

<https://la.mathworks.com/help/econ/assess-stationarity-of-time-series-using-econometric-modeler.html>

1. **Visualización:** El gráfico de la serie del PIB muestra una clara tendencia ascendente, sugiriendo no estacionariedad.
2. **Análisis de ACF:** La ACF decae muy lentamente, un patrón típico de una serie con raíz unitaria.
3. **Pruebas Formales (ADF y KPSS):** Ambas pruebas confirman que la serie es **no estacionaria**.
4. **Transformación:** Se aplica la **primera diferencia** para eliminar la tendencia.
5. **Reevaluación:** Las pruebas sobre la serie diferenciada confirman que ahora es **estacionaria** y está lista para ser modelada.

El Proceso de 'Quitar la Tendencia'

Objetivo Principal: Alcanzar la Estacionariedad

La diferenciación es el proceso más común para **estabilizar la media** de una serie temporal que no es estacionaria. Su principal propósito es **eliminar la tendencia**.

El Mecanismo: La Primera Diferencia

Se crea una nueva serie temporal calculando la diferencia entre cada observación y la anterior. La nueva serie representa los **cambios** o **incrementos** de un período al siguiente.

$$\Delta y_t = y_t - y_{t-1}$$

Intuición Visual de la Diferenciación

Serie Original (No Estacionaria)

Imagina una serie que crece constantemente con el tiempo (una tendencia lineal). Su media no es constante, por lo tanto, no es estacionaria.

- Su valor en el tiempo t es predeciblemente más alto que en $t - 1$.

Serie Diferenciada (Estacionaria)

Si calculamos la diferencia en cada paso (Δy_t), la nueva serie ya no mostrará la tendencia, sino que fluctuará alrededor de una media constante (el cambio promedio).

- Esta nueva serie de 'cambios' sí es estacionaria y está lista para ser modelada con ARMA.

En Resumen

Diferenciar es como pasar de ver la **posición** de un coche en una autopista a ver su **velocidad**. Si el coche sube una cuesta a velocidad constante (tendencia en la posición), su velocidad (la diferencia) será una línea plana (estacionaria).

Agenda

1. Introducción al Modelado de Series Temporales
2. Análisis de Correlación Pearson
 - 2.1 Correlación de Pearson
 - 2.2 Identificación de la Dependencia Temporal: ACF y PACF
3. Pruebas Estadísticas para la detección de estacionariedad
 - 3.1 La Prueba Q de Ljung-Box
 - 3.2 Detección de Volatilidad Condicional: Prueba de Efectos ARCH
 - 3.3 Pruebas de Raíz Unitaria
 - 3.4 Ejemplo Práctico: Detección de Estacionariedad
4. Modelos Autorregresivos Integrados de Media Móvil (ARIMA)
 - 4.1 Componentes Fundamentales: Procesos AR y MA
 - 4.2 El Modelo ARMA: Combinando Dependencia Pasada y Errores Aleatorios
 - 4.3 El Modelo ARIMA: Manejando la No Estacionariedad
 - 4.4 Extensiones del Modelo ARIMA
 - 4.5 La Metodología Box-Jenkins para el Modelado ARIMA

La Familia de Modelos ARIMA

Popularizada por Box y Jenkins, representa una de las clases de modelos más importantes y flexibles para el análisis y la predicción de series temporales.

Idea Central

El comportamiento de una serie temporal puede ser explicado por:

- Sus propios valores pasados → **Componente Autorregresivo (AR)**.
- Sus errores de predicción pasados → **Componente de Media Móvil (MA)**.

El Proceso Autorregresivo (AR)

Intuición

Modela el valor actual de la serie como una función lineal de sus valores pasados. La 'inercia' de la serie hace que los valores pasados sean buenos predictores del valor actual.

Modelo AR(p)

Un modelo Autorregresivo de orden p :

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

Identificación de un Proceso AR(p)

La 'firma' en los correlogramas es una **PACF** que se corta abruptamente después del rezago p y una **ACF** que decae exponencialmente.

El Proceso de Media Móvil (MA)

Intuición

Modela el valor actual de la serie como una función lineal de los errores de predicción pasados. Los 'choques' o 'sorpresas' aleatorias del pasado todavía tienen un efecto persistente.

Modelo MA(q)

Un modelo de Media Móvil de orden q :

$$y_t = \mu + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} + \cdots + \theta_q\epsilon_{t-q}$$

Identificación de un Proceso MA(q)

La 'firma' es una **ACF** que se corta abruptamente después del rezago q y una **PACF** que decae exponencialmente.

El Modelo ARMA: Combinando AR y MA

Combinando Componentes

En la práctica, muchas series temporales exhiben características tanto de procesos AR como MA. El modelo **Autorregresivo de Media Móvil (ARMA)** combina ambos para proporcionar un modelo más parsimonioso y flexible.

Modelo ARMA(p,q)

Un modelo ARMA(p,q) indica que el valor actual y_t depende de los p valores pasados de la serie y de los q errores de predicción pasados.

$$y_t = c + \underbrace{\phi_1 y_{t-1} + \cdots + \phi_p y_{t-p}}_{\text{Parte AR}(p)} + \epsilon_t + \underbrace{\theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}}_{\text{Parte MA}(q)}$$

El Modelo ARMA: Combinando AR y MA

Identificación

La identificación de modelos ARMA es más compleja, ya que tanto la ACF como la PACF tienden a decaer exponencialmente. La selección de los órdenes p y q a menudo se basa en **criterios de información** que equilibran el ajuste y la complejidad.

El Modelo ARIMA: Manejando la No Estacionariedad

El Problema: Series No Estacionarias

Los modelos AR, MA y ARMA requieren que la serie temporal sea **estacionaria** (con media y varianza constantes). Sin embargo, la mayoría de las series económicas y financieras reales tienen **tendencias** y, por lo tanto, no son estacionarias.

La Solución: El Componente 'Integrado' (I)

El modelo **Autorregresivo Integrado de Media Móvil (ARIMA)** extiende al ARMA para manejar estas series. El componente 'Integrado' se refiere al proceso de **diferenciación** para hacer que la serie sea estacionaria.

$$\Delta y_t = y_t - y_{t-1}$$

El Modelo ARIMA: Manejando la No Estacionariedad

Modelo ARIMA(p,d,q)

Se define por tres parámetros:

- **p:** El orden del componente Autorregresivo (AR).
- **d:** El número de veces que la serie necesita ser diferenciada.
- **q:** El orden del componente de Media Móvil (MA).

Un ARIMA(p,d,q) es, en esencia, un modelo ARMA(p,q) ajustado a la serie después de diferenciarla d veces.

Extensiones del Modelo ARIMA

Modelos Estacionales (SARIMA)

Para series que exhiben patrones estacionales (e.g., ventas que aumentan cada diciembre), se utiliza el modelo **ARIMA Estacional**.

Notación: ARIMA(p,d,q)(P,D,Q)s

- **(p,d,q)**: Términos no estacionales.
- **(P,D,Q)**: Términos estacionales.
- **s**: Periodicidad de la estacionalidad (e.g., s=12 para datos mensuales).

Inclusión de Predictores Externos (ARIMAX)

Para series cuyo comportamiento puede ser explicado por otras variables externas (exógenas).

Modelo: $y'_t = \beta x_t + \eta_t$

- El modelo extiende al ARIMA para incluir una o más variables predictoras (x_t).
- El término de error (η_t) se modela como un proceso ARMA.
- Útil para análisis de intervención.

Un Enfoque Iterativo para Construir Modelos ARIMA

Propuesto por Box y Jenkins, este es el proceso estándar y estructurado para la construcción de modelos ARIMA. Consta de tres etapas principales que se repiten hasta encontrar un modelo adecuado.

1. Identificación:

- Se determina si la serie es estacionaria y se identifica el orden de diferenciación (d) necesario usando gráficos y pruebas de raíz unitaria (ADF, KPSS).
- Se analizan la ACF y la PACF de la serie ya estacionaria para proponer órdenes tentativos para p y q .

La Metodología Box-Jenkins

1. Identificación:

- Se determina si la serie es estacionaria y se identifica el orden de diferenciación (d) necesario usando gráficos y pruebas de raíz unitaria (ADF, KPSS).
- Se analizan la ACF y la PACF de la serie ya estacionaria para proponer órdenes tentativos para p y q .

2. Estimación:

- Una vez identificado un modelo candidato ARIMA(p,d,q), se utilizan métodos numéricos (como máxima verosimilitud) para estimar los parámetros del modelo (ϕ_i, θ_j).

La Metodología Box-Jenkins

1. Identificación:

- Se determina si la serie es estacionaria y se identifica el orden de diferenciación (d) necesario usando gráficos y pruebas de raíz unitaria (ADF, KPSS).
- Se analizan la ACF y la PACF de la serie ya estacionaria para proponer órdenes tentativos para p y q .

2. Estimación:

- Una vez identificado un modelo candidato ARIMA(p,d,q), se utilizan métodos numéricos (como máxima verosimilitud) para estimar los parámetros del modelo (ϕ_i, θ_j).

3. Diagnóstico y Verificación:

- Se analizan los residuos del modelo (la diferencia entre los valores reales y los predichos).
- Los residuos deben comportarse como **ruido blanco** (sin autocorrelación) y seguir una distribución normal.

Ciclo Iterativo

Si el diagnóstico revela problemas (p. ej., correlación en los residuos), el proceso vuelve a la etapa de **Identificación** para probar un modelo diferente.

Creating ARIMA Models Using Econometric Modeler App

<https://la.mathworks.com/videos/creating-arima-models-using-econometric-modeler-app-1515711526970.html>